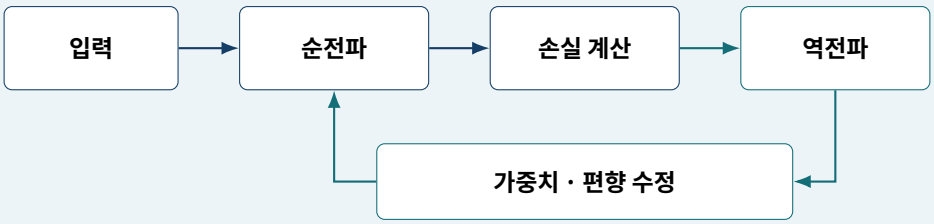
수학적 원리와 실제 숫자로 이해하는 AI 학습

# 퍼셉트론부터 인공신경망의 순전파 · 역전파까지

활성화 함수(선형 출력 포함) · 손실함수 · 경사하강법




## 이 자료의 구성

**개념별 설명** 각 개념에 '언제 · 어디서 · 어떻게 · 왜' 를 명시하고, 계산 예제를 하나씩 제시합니다.

**수학 공식** Sigmoid · Softmax · ReLU · 선형 출력, MSE · BCE · CCE, 최종 미분 공식과 가중치 갱신식을 정리합니다.

**공통 숫자 예제** **한 번의 순전파에서 계산한 예측값** $p = 0.5$를 그대로 손실과 역전파에 사용한 뒤, 매개변수를 수정하여 손실 변화를 확인합니다.

**미분 범위** 복잡한 미분 유도 과정은 생략합니다. 계산에 바로 적용하는 최종 기울기 공식을 제공합니다.

**학습의 핵심 질문** 신경망은 현재 가중치로 무엇을 예측하며, 그 예측의 오차를 줄이기 위해 **어떤 가중치를 어느 방향으로 수정**할까?

01 / BASIC CONCEPT

# 퍼셉트론: 인공 뉴런의 기본 계산

퍼셉트론(Perceptron)은 입력값마다 가중치를 곱하고 편향을 더한 뒤, 활성화 함수를 통해 최종 출력을 결정하는 가장 기본적인 인공 뉴런 모델입니다.

$$z = \sum_{i=1}^{n} w_i x_i + b, \qquad \hat{y} = f(z)$$

| 기호 | 의미 | 역할 |
|---|---|---|
| $x_i$ | 입력값 | 모델에 제공하는 특징 |
| $w_i$ | 가중치 | 입력 특징의 영향 정도와 방향 |
| $b$ | 편향 | 판단의 기준을 이동 |
| $z$ | 가중합 | 활성화 함수에 넣는 값 |
| $\hat{y}$ | 출력값 | 모델의 계산 또는 판단 결과 |

**언제** 이진 판단과 뉴런의 기본 계산 원리를 학습할 때 사용합니다.

**어디서** 개별 인공 뉴런 및 초기 신경망 구조를 설명할 때 사용합니다.

**어떻게** 입력 $x$와 가중치 $w$를 곱해 합산하고 편향 $b$를 더한 후 $f(z)$를 계산합니다.

**왜** 입력값이 판단 결과에 어떠한 영향을 주는지 수식으로 표현하기 위해서입니다.

**계산 예시: 계단 함수 퍼셉트론** $x_1 = 2,\ x_2 = 3,\ w_1 = 0.5,\ w_2 = -0.2,\ b = 0.1$

$$z = 2(0.5) + 3(-0.2) + 0.1 = 0.5$$

고전적인 계단 함수 $f(z) = 1\ (z \geq 0)$, $f(z) = 0\ (z < 0)$를 적용하면

$$\boxed{\hat{y} = f(0.5) = 1}$$

### 퍼셉트론의 한계와 학습

하나의 선형 결정 경계만 사용하는 고전적 단층 퍼셉트론은 XOR처럼 직선 하나로 분리되지 않는 문제를 해결하지 못합니다. 고전적 퍼셉트론의 학습 규칙은 다음과 같습니다.

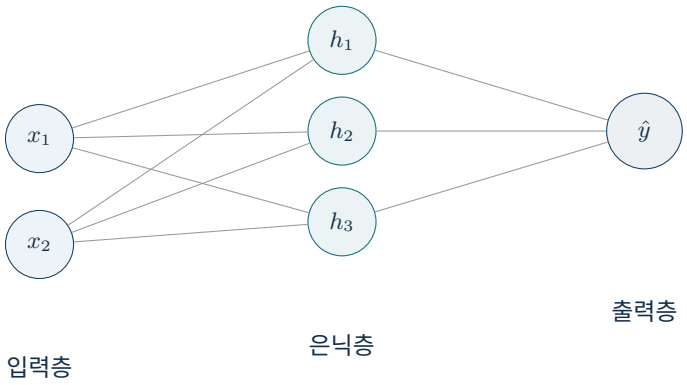
$$w_i^{\text{new}} = w_i^{\text{old}} + \eta(y - \hat{y})x_i, \quad b^{\text{new}} = b^{\text{old}} + \eta(y - \hat{y})$$

여기서 $\eta$는 학습률입니다. 뒤에서 다룰 다층 신경망의 **역전파+경사하강법**과는 구별합니다.

02 / NETWORK STRUCTURE

# 인공신경망: 뉴런을 층으로 연결하기

인공신경망(ANN)의 대표적인 형태인 다층 퍼셉트론(MLP)은 입력층, 하나 이상의 은닉층, 출력층으로 구성됩니다.




| 구성 | 기능 |
|---|---|
| **입력층** | 외부 데이터의 특징을 다음 층으로 전달 |
| **은닉층** | 가중합과 비선형 활성화 함수로 중간 특징 계산 |
| **출력층** | 문제에 맞는 예측 수치 또는 분류 확률 출력 |

**언제** 하나의 선형 경계로 설명하기 어려운 복잡한 입력·출력 관계를 학습할 때 사용합니다.

**어디서** 이미지·텍스트·표 데이터 등의 예측 모델에서, 특히 MLP의 은닉층에서 사용합니다.

**어떻게** 각 층에서 $z^{(\ell)} = W^{(\ell)}a^{(\ell-1)} + b^{(\ell)}$를 계산한 후 $a^{(\ell)} = f(z^{(\ell)})$를 적용합니다.

**왜** 비선형 관계를 여러 층에 걸쳐 표현할 수 있기 때문입니다. 선형 변환만 반복하면 여러 층을 합쳐 하나의 선형(아핀) 변환으로 나타낼 수 있습니다.

**간단 계산 예시: 은닉층 1개** 입력 $x = [1, 2]^T$, 은닉 가중치 $W = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$, 편향 $b = [0, 0]^T$ 라면

$$z = Wx + b = [1, 2]^T, \qquad h = ReLU(z) = [1, 2]^T.$$

출력층 가중치 $v = [0.5, 0.2]$와 편향 0을 적용하면 $z_o = 0.5(1) + 0.2(2) = 0.9$입니다.

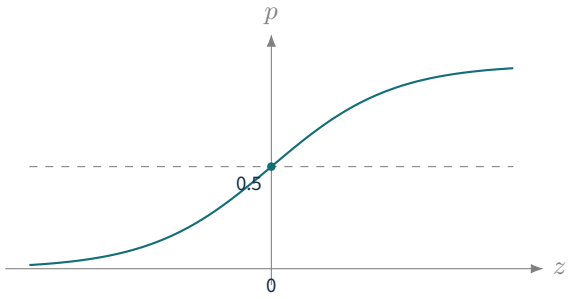
03 / ACTIVATION / 1

# Sigmoid: 이진 분류의 출력 확률

Sigmoid(시그모이드)는 실수인 가중합 $z$를 0과 1 사이로 변환합니다. 이진 분류에서 관심 클래스가 1일 예측 확률 $p$로 해석할 수 있습니다.

$$p = \sigma(z) = \frac{1}{1 + e^{-z}}$$

$$\sigma'(z) = \sigma(z)(1 - \sigma(z))$$




| | |
|---|---|
| 언제 | 정답이 0과 1 중 하나인 이진 분류를 학습하고 예측할 때 사용합니다. |
| 어디서 | 대표적으로 출력 뉴런 1개를 갖는 이진 분류 신경망의 출력층에 사용합니다. 은닉층에도 사용할 수 있지만 요즘 MLP에서는 ReLU가 흔합니다. |
| 어떻게 | 출력층 점수 $z$에 $\sigma(z)$를 적용해 확률 $p$를 구하고, 학습 시 BCE 손실을 계산합니다. |
| 왜 | 0 1 사이의 값으로 출력되므로 한 클래스에 대한 예측 확률로 해석하기 좋습니다. |

**계산 예시: 세 가지 입력값 비교** $e \approx 2.71828$

$$\sigma(-2) = \frac{1}{1+e^{2}} \approx 0.119, \quad \sigma(0) = \frac{1}{2} = 0.5, \quad \sigma(2) = \frac{1}{1+e^{-2}} \approx 0.881$$

입력이 증가하면 예측 확률도 증가합니다. 공통 신경망 예제는 $z = 0 \Rightarrow p = 0.5$를 사용합니다.

**주의:** $|z|$가 매우 크면 Sigmoid의 기울기가 작아져 은닉층에서 기울기 소실이 발생하기 쉽습니다. 출력이 확률처럼 보인다고 해서 확률의 신뢰성 보정(calibration)까지 보장되는 것은 아닙니다.

04 / ACTIVATION / 2

# Softmax: 여러 클래스의 확률 분포

Softmax(소프트맥스)는 $C$개 출력 뉴런의 점수 $z_1, \ldots, z_C$를 서로 비교하여 확률 분포 $p_1, \ldots, p_C$로 바꿉니다.

$$p_k = \frac{e^{z_k}}{\sum_{j=1}^{C} e^{z_j}}, \qquad \sum_{k=1}^{C} p_k = 1$$

**언제** 고양이/강아지/새처럼 여러 클래스 중 정확히 하나가 정답인 **배타적 다중 분류**에서 사용합니다.

**어디서** 클래스 수만큼 출력 뉴런을 두는 모델의 출력층에서 사용합니다.

**어떻게** 각 클래스 점수에 지수함수 $e^{z_k}$를 적용하고 전체 지수값의 합으로 나누어 각 클래스의 확률을 계산합니다. CCE 손실과 주로 결합합니다.

**왜** 점수의 상대적 크기를 유지하면서 모든 클래스의 확률 합을 1로 만들어 예측 결과를 비교할 수 있기 때문입니다.

**계산 예시: 고양이 · 강아지 · 새** $z = [2, 1, 0]$

$$e^2 \approx 7.389, \qquad e^1 \approx 2.718, \qquad e^0 = 1, \qquad S \approx 11.107$$

| 클래스 | 점수 $z_k$ | $e^{z_k}$ | 예측 확률 $p_k = e^{z_k}/S$ |
|---|---|---|---|
| **고양이** | 2 | 7.389 | $0.6652\ (66.52\%)$ |
| **강아지** | 1 | 2.718 | $0.2447\ (24.47\%)$ |
| **새** | 0 | 1 | $0.0900\ (9.00\%)$ |

반올림 때문에 표의 합이 정확히 1이 아닐 수 있지만, 실제 Softmax 결과의 합은 1입니다.

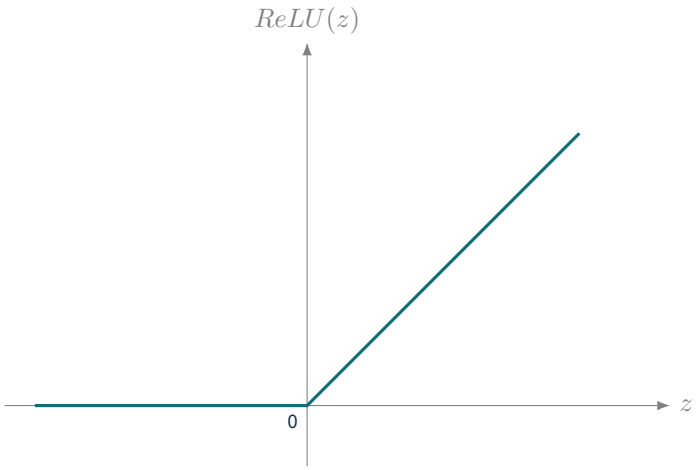
**사용상의 차이:** 여러 레이블을 동시에 정답으로 허용하는 문제(예: 한 사진에 사람·자동차가 동시에 존재)는 Softmax+CCE가 아닌 클래스별 Sigmoid+BCE가 일반적입니다. 수치 계산에서는 $z_k - \max_j z_j$를 이용한 안정화가 흔히 사용됩니다.

05 / ACTIVATION / 3

# ReLU: 은닉층에서 비선형 특징 학습

ReLU(Rectified Linear Unit)는 0보다 작은 입력을 0으로 만들고, 양수 입력은 그대로 전달하는 활성화 함수입니다.

$$ReLU(z) = \max(0, z) = \begin{cases} z & (z > 0) \\ 0 & (z \le 0) \end{cases}$$




| | |
|---|---|
| 언제 | 은닉층에서 복잡한 비선형 특징을 계산하고 신경망을 학습할 때 자주 사용합니다. |
| 어디서 | MLP · CNN 등 다양한 신경망의 은닉층에서 사용합니다. |
| 어떻게 | 은닉 뉴런의 가중합 $z$를 입력받아 $z > 0$이면 $z$, $z \le 0$이면 0을 출력합니다. 역전파 때는 양수 구간에서 기울기 1, 음수 구간에서 0을 적용합니다. |
| 왜 | 계산이 단순하고 양수 구간의 기울기가 일정하여 깊은 신경망 학습에 유리하기 때문입니다. |

**계산 예시: 두 은닉 뉴런** 같은 값이라도 입력 부호에 따라 출력이 달라집니다.

$$z_1 = 1.5 \Rightarrow h_1 = ReLU(1.5) = 1.5, \qquad z_2 = -0.8 \Rightarrow h_2 = ReLU(-0.8) = 0.$$

역전파에 이용하는 최종 미분값은 $ReLU'(1.5) = 1$, $ReLU'(-0.8) = 0$입니다.

**주의:** $z = 0$에서는 수학적으로 미분 불가능하나 실제 구현은 보통 기울기 0을 사용합니다. 음수 입력만 지속적으로 받는 뉴런은 기울기가 0이어서 학습하지 못하는 **죽은 ReLU(dead ReLU)** 문제가 생길 수 있습니다.

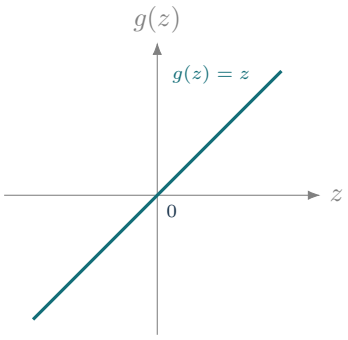
06 / ACTIVATION / 4

# 선형 출력: 연속적인 수치를 그대로 예측하기

선형 출력(Linear Output)은 출력층의 가중합을 별도 변환 없이 그대로 최종 예측값으로 사용하는 방식입니다. 활성화 함수 관점에서는 **항등 함수(Identity Function)** $g(z) = z$를 적용한 것과 같습니다. 여기서 '선형' 이라는 관용적 표현을 쓰지만 편향을 포함한 실제 계산은 엄밀하게는 아핀(affine) 변환입니다.

$$\hat{y} = g(z) = z = \sum_{j=1}^{m} v_j h_j + b_o$$

$$g'(z) = 1 \qquad (-\infty < \hat{y} < \infty)$$




| | |
|---|---|
| **언제** | 집값·기온·매출·소요 시간처럼 **연속적인 수치**를 예측하는 회귀 문제에서 대표적으로 사용합니다. |
| **어디서** | 은닉층에서 특징을 추출한 뒤 마지막 예측값을 만드는 **출력층**에 사용합니다. 중간 은닉층에는 보통 ReLU와 같은 비선형 함수를 둡니다. |
| **어떻게** | 출력층에서 $z = \sum_j v_j h_j + b_o$를 계산하고 $\hat{y} = z$를 그대로 출력합니다. 학습할 때는 정답 $y$와 비교해 MSE 등의 회귀 손실을 구합니다. |
| **왜** | Sigmoid처럼 $0 \sim 1$로 제한하지 않아 큰 값, 작은 값, 음수 등 다양한 실수 예측이 가능하기 때문입니다. 출력의 기울기가 1이라 기울기 계산도 간단합니다. |

**계산 예시: 연속값 예측 → 손실 → 한 번의 수정** 은닉층 출력 $h = 2$, 출력 가중치 $v = 0.6$, 편향 $b_o = 0.1$, 정답 $y = 2$, 학습률 $\eta = 0.05$입니다.

$$\hat{y} = g(vh + b_o) = g(0.6 \times 2 + 0.1) = \boxed{1.3}$$

$$L = (\hat{y} - y)^2 = (1.3 - 2)^2 = \boxed{0.49}$$

$$\frac{\partial L}{\partial v} = 2(\hat{y} - y)h = 2(1.3 - 2)(2) = \boxed{-2.8}, \quad \frac{\partial L}{\partial b_o} = 2(\hat{y} - y) = -1.4$$

$$v_{\text{new}} = 0.6 - 0.05(-2.8) = 0.74, \quad b_{\text{new}} = 0.1 - 0.05(-1.4) = 0.17$$

$$\hat{y}_{\text{new}} = 0.74(2) + 0.17 = 1.65, \quad L_{\text{new}} = (1.65 - 2)^2 = \boxed{0.1225}$$

순전파의 예측값 $1.3$으로 손실과 기울기를 구한 뒤 가중치·편향을 수정하자, 예측값은 정답 $2$에 가까워지고 손실은 $0.49 \rightarrow 0.1225$로 감소했습니다.

**주의:** 선형 출력은 확률을 만들지 않습니다. $\hat{y} = 1.3$은 130% 확률이 아닙니다. 예측값을 반드시 양수 또는 특정 구간으로 제한해야 하는 문제에서는 출력 함수나 목표값의 변환 등을 별도로 설계해야 합니다.

07 / CHOOSING ACTIVATIONS

# 활성화 함수의 선택과 자연상수 $e$

실제 신경망에서는 은닉층과 출력층의 목적이 다르므로 사용하는 활성화 함수도 달라집니다.

| 함수 | 대표 위치 | 출력 범위 | 사용 이유 |
|---|---|---|---|
| **Sigmoid** | 이진 분류 출력층 | $0 < p < 1$ | 한 클래스에 대한 확률 출력 |
| **Softmax** | 배타적 다중 분류 출력층 | $0 < p_k < 1$, 합 1 | 여러 클래스의 확률 분포 |
| **ReLU** | 은닉층 | $[0, \infty)$ | 비선형 특징 표현과 간단한 기울기 계산 |
| **선형(항등)** | 회귀 출력층 | 실수 전체 | 집값·온도 등의 연속적인 수치 예측 |

## 지수함수와 자연상수 $e$

Sigmoid와 Softmax에 등장하는 $e$는 학습으로 바뀌는 가중치가 아니라 **자연상수**입니다.

$$\boxed{e \approx 2.718281828\ldots}, \qquad e^0 = 1, \qquad \frac{d}{dz}e^z = e^z$$

자연로그 $\ln(p)$는 밑이 $e$인 로그를 뜻합니다. BCE와 CCE에서 예측 확률이 정답에 얼마나 불리한지 측정할 때 사용합니다.

**언제**
지수함수는 Sigmoid · Softmax 계산 시, 자연로그는 BCE · CCE 손실 계산 시 등장합니다.

**어디서**
출력층의 활성화 함수와 분류 손실함수 내부에서 사용됩니다.

**어떻게**
$e^z$를 계산하거나 $\ln(p)$를 계산합니다. ln과 지수함수는 서로 역함수 관계입니다.

**왜**
지수함수는 항상 양수이며 미분 성질이 단순해 확률 변환과 최적화 수식에 편리합니다.

**계산 예시: $e$가 들어간 두 계산**

$$\sigma(0) = \frac{1}{1+e^0} = \frac{1}{2} = 0.5, \qquad -\ln(0.5) \approx 0.6931.$$

첫 식은 **확률 출력**, 두 번째 식은 **정답 1일 때의 BCE 손실**입니다. 동일한 0.5가 두 단계에서 연결됩니다.

**선택 요령:** 연속값 예측은 선형 출력, 이진 분류는 Sigmoid, 서로 배타적인 3개 이상 클래스 분류는 Softmax가 대표적입니다. 다중 레이블 분류는 레이블마다 Sigmoid를 씁니다.

08 / FORWARD PROPAGATION

# 순전파: 입력에서 최종 예측까지

순전파(Forward Propagation)는 **현재**의 가중치와 편향을 사용해 입력값을 한 층씩 처리하여 예측값을 얻는 계산입니다. 순전파 자체는 가중치를 수정하지 않습니다.

$$z^{(1)} = W^{(1)}x + b^{(1)} \longrightarrow h = f(z^{(1)})$$
$$z^{(2)} = W^{(2)}h + b^{(2)} \longrightarrow \hat{y} = g(z^{(2)})$$

**언제** 학습 중 손실을 계산하기 전과, 학습된 모델로 새로운 데이터를 예측할 때 사용합니다.

**어디서** 입력층에서 은닉층을 거쳐 출력층으로 진행하는 전체 신경망에 적용됩니다.

**어떻게** 각 뉴런마다 가중합 $z$를 계산하고 활성화 함수에 대입합니다. 이전 층의 출력이 다음 층의 입력이 됩니다.

**왜** 입력으로부터 예측을 생성해야 정답과 비교하고 손실을 계산할 수 있기 때문입니다.

**독립 계산 예시: 입력 1개 → ReLU 은닉 뉴런 1개 → Sigmoid 출력 1개**

1. 입력 $x = 2$, 은닉 가중치 $w = 0.5$, 은닉 편향 $b = -0.2$이므로 $z_h = 0.5(2) - 0.2 = 0.8$.
2. 은닉층 출력 $h = ReLU(0.8) = 0.8$.
3. 출력 가중치 $v = 1$, 출력 편향 $b_o = 0$이므로 $z_o = 1(0.8) + 0 = 0.8$.
4. 최종 확률 $p = \sigma(0.8) = 1/(1 + e^{-0.8}) \approx \boxed{0.6900}$.

## 문제 유형에 따라 마지막 단계만 달라집니다

| 문제 | 출력층 함수 $g$ | 출력의 해석 |
|---|---|---|
| **회귀(가격 예측)** | 선형 함수 $g(z) = z$ | 실수값 예측 |
| **이진 분류** | $g(z) = \sigma(z)$ | 관심 클래스가 1일 확률 |
| **배타적 다중 분류** | $g(z) = Softmax(z)$ | 클래스별 확률의 합이 1 |

**통합 예제와의 연결:** 뒤에서는 입력 $x_1 = 1, x_2 = 2$와 은닉 뉴런 2개를 가진 신경망을 끝까지 추적합니다. 그때 순전파가 만든 $p = 0.5$를 다시 임의로 바꾸지 않고 역전파에 그대로 사용합니다.

09 / LOSS / MSE

# 손실함수와 MSE: 수치 예측의 오차

손실함수(Loss Function) $L(y, \hat{y})$는 모델의 예측값과 실제 정답의 차이를 수치화합니다. 학습은 이 손실을 줄이도록 매개변수를 조정하는 과정입니다. **MSE: 평균제곱오차(Mean Squared Error)**

$$MSE = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2$$

| | |
|---|---|
| 언제 | 집값·매출·온도처럼 연속된 수치를 예측하는 회귀 문제의 학습에 사용합니다. |
| 어디서 | 회귀 모델의 출력과 실제 연속값을 비교하는 손실 계산 단계에서 사용합니다. |
| 어떻게 | 각 데이터의 예측오차를 제곱하고 전체 데이터 개수 $N$으로 나누어 평균냅니다. |
| 왜 | 양수·음수 오차가 상쇄되지 않고, 큰 오차에 더 큰 불이익을 주기 때문입니다. |

**계산 예시: 집값 예측(단위: 억 원)**

| 데이터 | 실제값 $y$ | 예측값 $\hat{y}$ | 제곱오차 $(y-\hat{y})^2$ |
|---|---|---|---|
| A | 3 | 2 | $(3-2)^2 = 1$ |
| B | 5 | 4 | $(5-4)^2 = 1$ |
| C | 7 | 9 | $(7-9)^2 = 4$ |

$$\boxed{MSE = \frac{1+1+4}{3} = 2}$$

## 역전파에서 쓰는 MSE의 두 표현

단일 데이터의 제곱오차 $L = (\hat{y} - y)^2$를 쓰면

$$\frac{\partial L}{\partial w} = 2(\hat{y} - y)x \qquad (\hat{y} = wx + b).$$

미분 계산을 간단히 하려고 $L = \frac{1}{2}(\hat{y} - y)^2$를 쓰면

$$\frac{\partial L}{\partial w} = (\hat{y} - y)x.$$

**구분:** 위 두 식은 손실함수의 정의가 다릅니다. 이 자료에서는 MSE의 원래 정의와 단일 샘플용 반제곱오차를 명확히 구별합니다. 출력층이 선형인 예시에 대한 공식이며, 여러 샘플 평균에서는 평균 기울기를 사용합니다.

10 / LOSS / BCE

# BCE: 이진 분류의 확률 오차

BCE(Binary Cross-Entropy, 이진 교차 엔트로피)는 정답 $y \in \{0, 1\}$과 Sigmoid가 예측한 확률 $0 < p < 1$을 비교합니다.

$$BCE = -\left[y \ln(p) + (1 - y) \ln(1 - p)\right]$$

**언제** 참/거짓, 스팸/정상처럼 정답이 두 개인 분류 문제에서 사용합니다.

**어디서** Sigmoid 출력층 다음의 학습 손실 계산에 사용합니다. 다중 레이블 문제에서는 레이블별로도 사용할 수 있습니다.

**어떻게** 정답 $y = 1$일 때 $-\ln(p)$, 정답 $y = 0$일 때 $-\ln(1 - p)$로 계산합니다.

**왜** 정답에 작은 확률을 줄수록 큰 손실을 부여하여 올바른 확률 예측을 유도하기 때문입니다.

**계산 예시: 정답이 스팸($y = 1$)인 메일**

| 예측 상황 | 스팸 확률 $p$ | BCE 계산 |
|---|---|---|
| **정답에 높은 확률** | 0.8 | $-\ln(0.8) \approx 0.2231$ |
| **정답에 낮은 확률** | 0.1 | $-\ln(0.1) \approx 2.3026$ |
| **판단이 불확실** | 0.5 | $-\ln(0.5) \approx 0.6931$ |

정답 클래스에 대한 확률이 낮을수록 손실이 커집니다. 공통 예제는 $p = 0.5$, $y = 1$이므로 $L = 0.6931$입니다.

## 역전파에 바로 쓰는 핵심 결합 공식

Sigmoid 출력 $p = \sigma(wx + b)$와 BCE를 **함께** 사용할 때,

$$\frac{\partial L}{\partial z} = p - y, \quad \frac{\partial L}{\partial w} = (p - y)x, \quad \frac{\partial L}{\partial b} = p - y$$

**주의:** $\ln(0)$은 정의되지 않으므로 실제 프로그램에서는 0이나 1에 너무 가까운 확률에 대한 수치 안정성을 고려합니다. 많은 딥러닝 라이브러리는 Sigmoid와 BCE를 로짓(logit) 기반의 안정적인 연산으로 합쳐 제공합니다.

11 / LOSS / CCE

# CCE: 다중 분류의 확률 오차

CCE(Categorical Cross-Entropy, 범주형 교차 엔트로피)는 여러 클래스 중 **하나만 정답**인 분류의 손실을 계산합니다. 정답은 보통 원-핫 벡터 $y$로 표현합니다.

$$CCE = -\sum_{k=1}^{C} y_k \ln(p_k)$$

| | |
|---|---|
| 언제 | 서로 배타적인 3개 이상 클래스 중 한 클래스를 분류할 때 사용합니다. |
| 어디서 | Softmax 출력층 다음의 손실 계산 단계에서 사용합니다. |
| 어떻게 | 정답 클래스의 원-핫 값만 1이고 나머지는 0이므로, 정답 클래스 확률 $p_{\text{true}}$에 대해 $-\ln(p_{\text{true}})$가 됩니다. |
| 왜 | 틀린 클래스에 확률을 많이 분산하거나 정답 클래스에 낮은 확률을 주는 예측을 크게 벌점화하기 때문입니다. |

**계산 예시: 고양이·강아지·새 분류**

$$y = [1, 0, 0], \qquad p = [0.7, 0.2, 0.1].$$

$$L = -\left[1 \ln(0.7) + 0 \ln(0.2) + 0 \ln(0.1)\right]$$

$$\boxed{L = -\ln(0.7) \approx 0.3567}$$

이 모델은 정답 고양이에 70%의 확률을 부여했습니다. 정답 확률이 0.9라면 손실은 $-\ln(0.9) \approx 0.1054$로 더 작아집니다.

## Softmax+CCE의 최종 기울기

$$\frac{\partial L}{\partial z_k} = p_k - y_k, \qquad \frac{\partial L}{\partial w_k} = (p_k - y_k)x$$

이는 단일 입력 $x$, 클래스별 점수 $z_k = w_k x + b_k$인 경우입니다.

**주의:** CCE는 모든 클래스가 동시에 정답일 수 있는 문제보다 배타적 다중 분류에 적합합니다. 정답을 클래스 번호로 저장한다면 구현상 sparse categorical cross-entropy를 사용할 수 있습니다.

12 / LOSS SELECTION

# 손실함수는 언제 무엇을 선택할까?

손실함수는 모델 출력값의 의미와 학습 문제에 따라 정합니다. 같은 숫자라도 예측값이 연속값인지, 확률인지에 따라 적절한 손실함수가 달라집니다.

| 문제 유형 | 대표 출력층 | 대표 손실 | 사용 이유 |
|---|---|---|---|
| **회귀** | 선형 출력 | MSE | 연속 수치의 차이 최소화 |
| **이진 분류** | Sigmoid | BCE | 0/1 정답의 확률 오차 |
| **배타적 다중 분류** | Softmax | CCE | 정답 클래스의 예측 확률 강화 |
| **다중 레이블 분류** | 클래스별 Sigmoid | 레이블별 BCE | 여러 레이블의 동시 정답 허용 |

**언제** 신경망의 출력층과 학습 목적을 설계할 때 선택합니다.

**어디서** 순전파의 마지막 출력값과 정답값을 비교하는 지점에서 사용합니다.

**어떻게** 정답 표현(실수, 0/1, 원-핫 벡터)을 확인하고 그 출력에 맞는 손실을 적용합니다.

**왜** 맞지 않는 손실함수를 선택하면 학습 목표와 출력값의 의미가 어긋나기 때문입니다.

**비교 계산 예시: 어떤 문제에서 어떤 식을 쓸까?**

1. **집값:** 정답 $y = 3$, 예측 $\hat{y} = 2$ → 단일 제곱오차 $(3-2)^2 = 1$.
2. **스팸 여부:** 정답 $y = 1$, 예측 확률 $p = 0.8$ → BCE $= -\ln(0.8) \approx 0.2231$.
3. **동물 세 종류:** 정답 $y = [1, 0, 0]$, 예측 $p = [0.7, 0.2, 0.1]$ → CCE $\approx 0.3567$.

## 여러 데이터로 학습할 때

이 자료의 공통 숫자 예제는 **데이터 1개**로 계산합니다. 데이터 $N$개에 대한 평균 손실을 사용한다면, 손실과 그에 따른 가중치 기울기를 샘플별로 구해 평균낸 값으로 업데이트합니다.

$$\overline{L} = \frac{1}{N}\sum_{i=1}^{N} L_i, \qquad \frac{\partial \overline{L}}{\partial w} = \frac{1}{N}\sum_{i=1}^{N} \frac{\partial L_i}{\partial w}$$

**핵심 연결:** 출력층의 활성화 함수는 예측을 어떤 값으로 표현할지 결정하고, 손실함수는 그 예측을 정답과 어떻게 비교할지 결정합니다.

13 / BACKPROPAGATION

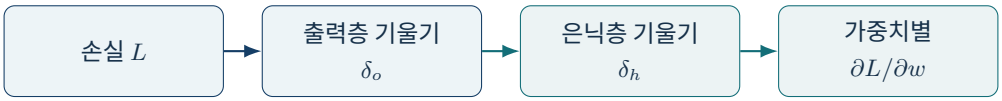
# 역전파: 손실이 가중치에 미치는 영향

역전파(Backpropagation)는 순전파에서 계산한 출력과 손실을 이용해 **각 가중치·편향에 대한 손실의 기울기**를 출력층에서 앞쪽 층 방향으로 계산하는 알고리즘입니다.

$$\frac{\partial L}{\partial w} = \text{가중치 } w\text{를 조금 바꿀 때 손실 } L\text{이 변하는 비율}$$

| | |
|---|---|
| 언제 | 순전파로 예측하고 손실을 계산한 **이후**, 학습 단계에서 사용합니다. |
| 어디서 | 출력층에서 출발해 은닉층 방향으로 전달되며, 학습할 가중치·편향 전체에 적용됩니다. |
| 어떻게 | 출력층 오차 기울기를 먼저 구하고, 연결 가중치와 은닉층 활성화 함수의 기울기를 이용해 앞층으로 전달합니다. |
| 왜 | 매개변수마다 손실에 미치는 영향이 다르므로, 각각의 수정 방향과 크기를 계산해야 하기 때문입니다. |

## 역전파의 순서




## 다층 신경망에서 바로 사용하는 일반 형태

$$\delta^{(\ell)} = \left[(W^{(\ell+1)})^T \delta^{(\ell+1)}\right] \odot f'(z^{(\ell)})$$
$$\frac{\partial L}{\partial W^{(\ell)}} = \delta^{(\ell)} (a^{(\ell-1)})^T, \qquad \frac{\partial L}{\partial b^{(\ell)}} = \delta^{(\ell)}$$

$\odot$는 원소별 곱셈이고, $\delta^{(\ell)}$는 해당 층의 가중합에 대한 손실 기울기입니다. 위 식은 단일 샘플의 일반적인 완전연결층 표현입니다.

**간단 계산 예시: 출력층에서 출발** Sigmoid+BCE, $p = 0.5$, 정답 $y = 1$이라면

$$\boxed{\delta_o = \frac{\partial L}{\partial z_o} = p - y = 0.5 - 1 = -0.5}.$$

이 $-0.5$가 출력층 가중치 기울기와 은닉층 기울기를 구하는 시작점입니다.

14 / GRADIENT FORMULAS

# 역전파에서 쓰는 최종 미분 공식

복잡한 유도 과정 없이 수치 대입에 사용할 결과만 모았습니다. 아래의 단순 가중치 공식은 **데이터 1개, 하나의 입력** $x$를 기준으로 합니다.

| 조합/위치 | 최종 공식 |
|---|---|
| **선형 출력 + 제곱오차** | $\frac{\partial L}{\partial w} = 2(\hat{y}-y)x \; (L=(\hat{y}-y)^2)$ |
| **선형 출력 + 반제곱오차** | $\frac{\partial L}{\partial w} = (\hat{y}-y)x \; (L=\frac{1}{2}(\hat{y}-y)^2)$ |
| **Sigmoid + BCE** | $\delta_o = p-y,\ \frac{\partial L}{\partial w} = (p-y)x$ |
| **Softmax + CCE** | $\delta_k = p_k - y_k,\ \frac{\partial L}{\partial w_k} = (p_k-y_k)x$ |
| **ReLU 은닉층** | $\delta_j = \delta_o v_j ReLU'(a_j),\ \frac{\partial L}{\partial w_{ji}} = \delta_j x_i$ |

**언제** 출력값으로 손실을 구한 뒤, 가중치 업데이트 전에 사용합니다.

**어디서** 출력층과 은닉층 각각의 연결 가중치에 적용합니다.

**어떻게** 각 조합에 맞는 기울기 공식에 순전파 출력 $\hat{y}$ 또는 $p$, 정답 $y$, 입력값 등을 대입합니다.

**왜** 복잡한 미분 계산을 반복하지 않고 학습에 필요한 수치 기울기를 효율적으로 구하기 위해서입니다.

**각 최종 공식에 숫자 대입**

1. **제곱오차:** $x=2,\ \hat{y}=2,\ y=3 \rightarrow 2(2-3)(2) = \boxed{-4}$.
2. **Sigmoid+BCE:** $x=2,\ p=0.5,\ y=1 \rightarrow (0.5-1)(2) = \boxed{-1}$.
3. **Softmax+CCE:** $x=2,\ p=[0.7,0.2,0.1],\ y=[1,0,0] \rightarrow \partial L/\partial w = [-0.6, 0.4, 0.2]$.
4. **ReLU 은닉:** $\delta_o=-0.5,\ v=1,\ a=1,\ x=2 \rightarrow \delta_h=-0.5$와 $\partial L/\partial w = -1$.

**주의:** 출력층 기울기와 은닉층 가중치 기울기를 혼동하면 안 됩니다. 여러 층에서 필요한 기울기를 모두 계산할 때까지 기존의 가중치를 유지합니다.

15 / OPTIMIZATION

# 경사하강법: 계산한 기울기로 수정하기

경사하강법(Gradient Descent)은 역전파가 계산한 기울기를 이용해 손실이 줄어드는 방향으로 가중치와 편향을 바꾸는 최적화 방법입니다.

$$w_{\text{new}} = w_{\text{old}} - \eta \frac{\partial L}{\partial w}$$

$$b_{\text{new}} = b_{\text{old}} - \eta \frac{\partial L}{\partial b}$$

| | |
|---|---|
| **언제** | 역전파로 매개변수별 기울기를 모두 계산한 직후 사용합니다. |
| **어디서** | 출력층·은닉층의 학습 가능한 가중치와 편향을 업데이트하는 단계에서 사용합니다. |
| **어떻게** | 현재 가중치에서 학습률 $\eta$와 기울기를 곱한 양을 뺍니다. 다른 매개변수도 같은 방식으로 바꿉니다. |
| **왜** | 기울기의 반대 방향이 현재 위치에서 손실을 줄이는 국소적인 방향이기 때문입니다. |

**계산 예시: 학습률** $\eta = 0.1$

$$w_{\text{old}} = 1, \qquad \frac{\partial L}{\partial w} = -0.5$$

$$\boxed{w_{\text{new}} = 1 - 0.1(-0.5) = 1.05}$$

기울기가 음수이므로 가중치가 증가합니다. 반대로 기울기가 $+0.5$라면 $w_{\text{new}} = 0.95$가 됩니다.

## 학습률의 의미

| 상황 | 결과 |
|---|---|
| **학습률이 너무 큼** | 최솟값을 지나치거나 손실이 오히려 증가할 수 있음 |
| **학습률이 너무 작음** | 한 번의 업데이트 변화가 작아 학습이 느려질 수 있음 |
| **적절한 학습률** | 안정적으로 손실을 줄이는 데 도움을 줄 수 있음 |

**역전파와 경사하강법의 차이:** **역전파**는 기울기를 구하는 알고리즘이고, **경사하강법**은 그 기울기를 사용해 매개변수를 수정하는 방법입니다. 수정 후 손실이 매번 감소한다고 보장되지는 않습니다.

16 / ONE CONNECTED EXAMPLE / 1

# 공통 예제 ① 초기값과 순전파

이제부터 **한 개의 신경망과 동일한 데이터**를 끝까지 사용합니다. 앞 단계의 출력을 다음 단계에 그대로 넣어 순전파 → BCE 손실 → 출력층 역전파 → 은닉층 역전파 → 가중치 수정 → 재예측까지 연결합니다. **문제 설정**

입력 2개 → ReLU 은닉 뉴런 2개 → Sigmoid 출력 뉴런 1개 → BCE 손실.

$$x_1 = 1, \quad x_2 = 2, \quad y = 1, \quad \eta = 0.1$$

| 구성 | 초기 매개변수 |
|---|---|
| **은닉 뉴런 1** | $w_{11} = 1,\ w_{12} = 0,\ b_1 = 0$ |
| **은닉 뉴런 2** | $w_{21} = -1,\ w_{22} = 0,\ b_2 = 0$ |
| **출력 뉴런** | $v_1 = 1,\ v_2 = 1,\ b_o = -1$ |

## 1단계. 은닉층 가중합과 ReLU 출력

$$a_1 = w_{11}x_1 + w_{12}x_2 + b_1 = 1(1) + 0(2) + 0 = 1$$

$$\boxed{h_1 = ReLU(a_1) = ReLU(1) = 1}$$

$$a_2 = w_{21}x_1 + w_{22}x_2 + b_2 = (-1)(1) + 0(2) + 0 = -1$$

$$\boxed{h_2 = ReLU(a_2) = ReLU(-1) = 0}$$

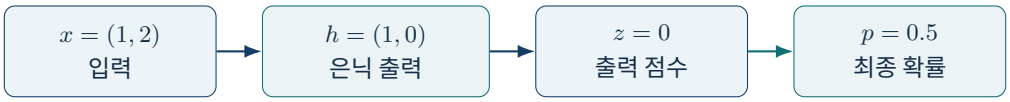
## 2단계. 출력층 점수와 Sigmoid 확률

$$z = v_1h_1 + v_2h_2 + b_o = 1(1) + 1(0) - 1 = 0$$

$$\boxed{p = \sigma(z) = \frac{1}{1 + e^0} = 0.5}$$

**중요:** 순전파가 계산한 값은 $h_1 = 1$, $h_2 = 0$, $z = 0$, $p = 0.5$입니다. 다음 모든 역전파 계산은 바로 이 값에서 시작합니다.

## 순전파에서 구한 숫자의 전달 경로



17 / ONE CONNECTED EXAMPLE / 2

# 공통 예제 ② BCE 손실과 출력층 기울기

**직전 페이지의 순전파 결과** $p = 0.5$를 바꾸지 않고 사용합니다. 정답은 $y = 1$입니다. **3단계. 순전파 출력으로 BCE 손실 계산**

$$L = -[y \ln(p) + (1-y)\ln(1-p)]$$
$$= -[1 \ln(0.5) + 0 \ln(0.5)] = -\ln(0.5)$$

$$\boxed{L \approx 0.6931}$$

## 4단계. 같은 출력값으로 출력층 역전파

출력층이 Sigmoid, 손실함수가 BCE이므로 최종 미분 공식은

$$\delta_o = \frac{\partial L}{\partial z} = p - y.$$

따라서 순전파로 구한 $p = 0.5$를 대입하면

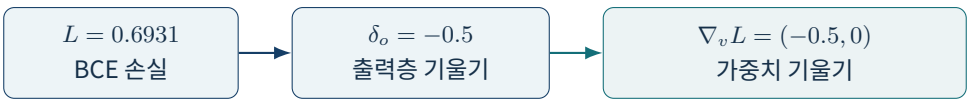
$$\boxed{\delta_o = 0.5 - 1 = -0.5}$$

출력층 가중치의 기울기는 **출력층 기울기** $\times$ **은닉층 출력값**입니다.

| 구할 기울기 | 계산 | 결과 |
|---|---|---|
| $\partial L/\partial v_1$ | $\delta_o h_1 = (-0.5)(1)$ | $-0.5$ |
| $\partial L/\partial v_2$ | $\delta_o h_2 = (-0.5)(0)$ | $0$ |
| $\partial L/\partial b_o$ | $\delta_o$ | $-0.5$ |

**연결 확인** **순전파** $p = 0.5 \rightarrow$ **손실** $L = 0.6931 \rightarrow$ **출력층 기울기** $\delta_o = -0.5$.
은닉 뉴런 2의 출력 $h_2 = 0$이므로 $v_2$의 기울기는 0입니다. 그러나 은닉층의 기울기를 계산할 때는 수정 전 연결 가중치 $v_1 = v_2 = 1$을 사용합니다.

## 손실에서 출력층 가중치로 이어지는 역전파



18 / ONE CONNECTED EXAMPLE / 3

# 공통 예제 ③ 은닉층 역전파

출력층에서 얻은 $\delta_o = -0.5$와 **수정하기 전의 가중치** $v_1 = v_2 = 1$을 사용합니다. **5단계. 출력층 기울기를 은닉층으로 전달**

$$\delta_j = \frac{\partial L}{\partial a_j} = \delta_o \, v_j \, ReLU'(a_j)$$

| 은닉 뉴런 | 순전파 $a_j$ | $ReLU'(a_j)$ | 기울기 $\delta_j$ |
|---|---|---|---|
| **은닉 1** | $1$ | $1$ | $(-0.5)(1)(1) = -0.5$ |
| **은닉 2** | $-1$ | $0$ | $(-0.5)(1)(0) = 0$ |

## 6단계. 은닉층 가중치와 편향의 기울기

$$\frac{\partial L}{\partial w_{ji}} = \delta_j x_i, \qquad \frac{\partial L}{\partial b_j} = \delta_j$$

| 매개변수 기울기 | 값 대입 | 결과 |
|---|---|---|
| $\partial L/\partial w_{11}$ | $(-0.5)x_1 = (-0.5)(1)$ | $-0.5$ |
| $\partial L/\partial w_{12}$ | $(-0.5)x_2 = (-0.5)(2)$ | $-1.0$ |
| $\partial L/\partial b_1$ | $\delta_1$ | $-0.5$ |
| $\partial L/\partial w_{21}$ | $(0)x_1$ | $0$ |
| $\partial L/\partial w_{22}$ | $(0)x_2$ | $0$ |
| $\partial L/\partial b_2$ | $\delta_2$ | $0$ |

**왜 0이 나왔을까?** 순전파 때 은닉 뉴런 2의 가중합 $a_2 = -1$이었습니다. ReLU는 음수 구간에서 기울기가 0이므로 이 데이터에서는 은닉 2에 연결된 입력 가중치와 편향의 기울기가 모두 0입니다. 다른 데이터에서는 달라질 수 있습니다.

## ReLU가 은닉층 기울기를 전달하거나 차단하는 원리

은닉 1: $a_1 = 1 > 0$
$ReLU'(a_1) = 1,\ \delta_1 = -0.5$

은닉 2: $a_2 = -1 < 0$
$ReLU'(a_2) = 0,\ \delta_2 = 0$

19 / ONE CONNECTED EXAMPLE / 4

# 공통 예제 ④ 경사하강법으로 모두 수정

이제 출력층·은닉층의 기울기를 모두 계산했습니다. 학습률 $\eta = 0.1$로 **모든 매개변수를 한 번에** 수정합니다.

$$\theta_{\text{new}} = \theta_{\text{old}} - 0.1\frac{\partial L}{\partial \theta}$$

| 매개변수 | 수정 전 | 기울기 | 계산 | 수정 후 |
|---|---|---|---|---|
| $w_{11}$ | $1$ | $-0.5$ | $1-0.1(-0.5)$ | $1.05$ |
| $w_{12}$ | $0$ | $-1.0$ | $0-0.1(-1)$ | $0.10$ |
| $b_1$ | $0$ | $-0.5$ | $0-0.1(-0.5)$ | $0.05$ |
| $w_{21}$ | $-1$ | $0$ | $-1-0.1(0)$ | $-1$ |
| $w_{22}$ | $0$ | $0$ | $0-0.1(0)$ | $0$ |
| $b_2$ | $0$ | $0$ | $0-0.1(0)$ | $0$ |
| $v_1$ | $1$ | $-0.5$ | $1-0.1(-0.5)$ | $1.05$ |
| $v_2$ | $1$ | $0$ | $1-0.1(0)$ | $1$ |
| $b_o$ | $-1$ | $-0.5$ | $-1-0.1(-0.5)$ | $-0.95$ |

## 수정 전후의 값에서 확인할 점

- 기울기가 $-0.5$인 $w_{11}$은 $1 \to 1.05$로 증가합니다.
- 기울기가 $-1.0$인 $w_{12}$는 $0 \to 0.10$으로 증가합니다.
- 기울기가 0인 은닉 2의 매개변수 $w_{21}, w_{22}, b_2$는 이번 업데이트에서 그대로입니다.
- 출력층의 $v_1$과 $b_o$도 동시에 수정됩니다.

**업데이트 규칙:** 역전파 중간에 일부 가중치를 먼저 수정해서는 안 됩니다. 처음 순전파 시점의 가중치로 모든 기울기를 계산하고, 그다음 매개변수를 업데이트합니다.

## 가중치 수정의 방향을 읽는 방법

기울기 $< 0$
$w_{11} : 1 \longrightarrow 1.05$

기울기 $= 0$
$w_{21} : -1 \longrightarrow -1$

20 / ONE CONNECTED EXAMPLE / 5

# 공통 예제 ⑤ 다시 순전파하여 검증

업데이트한 매개변수를 가지고 **같은 입력** $x_1 = 1, x_2 = 2$를 다시 순전파합니다. 학습 전·후 손실이 실제로 어떻게 달라졌는지 확인합니다. **7단계. 업데이트된 은닉층**

$$a_1' = 1.05(1) + 0.10(2) + 0.05 = 1.30 \quad \Rightarrow \quad h_1' = ReLU(1.30) = 1.30$$
$$a_2' = (-1)(1) + 0(2) + 0 = -1 \quad \Rightarrow \quad h_2' = ReLU(-1) = 0$$

## 8단계. 업데이트된 출력층과 BCE 손실

$$z' = 1.05(1.30) + 1(0) - 0.95 = 0.415$$
$$\boxed{p' = \sigma(0.415) \approx 0.6023}$$
$$\boxed{L' = -\ln(0.6023) \approx 0.5070}$$

**처음 순전파와 수정 후 순전파 비교**

| 비교 항목 | 수정 전 | 수정 후 |
|---|---|---|
| **예측 확률 $p$ (정답 $y = 1$)** | 0.5000 | 0.6023 |
| **BCE 손실 $L$** | 0.6931 | 0.5070 |
| **은닉 1 출력** | 1.00 | 1.30 |
| **은닉 2 출력** | 0 | 0 |

BCE 손실이 약 $0.1861$ 감소했습니다. 이는 같은 순전파 결과에서 역전파로 계산한 기울기를 이용해 은닉층과 출력층의 매개변수를 수정했기 때문입니다.

**학습의 전체 연결:** 입력 $\rightarrow$ 순전파$(p = 0.5)$ $\rightarrow$ BCE$(0.6931)$ $\rightarrow$ 역전파$(\delta_o = -0.5)$ $\rightarrow$ 매개변수 수정 $\rightarrow$ 재순전파 $(p \approx 0.6023)$ $\rightarrow$ 새 손실$(0.5070)$.
이 예시에서는 손실이 감소했지만, 실제 학습에서 매 업데이트마다 손실이 줄어든다는 보장은 없습니다.

## 수정 전·후 예측의 비교를 해석하기




정답이 $y = 1$인 샘플에서 확률이 $0.5$에서 약 $0.6023$으로 올라갔으며, 이에 따라 BCE가 $0.6931$에서 약 $0.5070$으로 감소했습니다.

21 / FORMULA REFERENCE

# 핵심 공식과 사용 위치 총정리

| 개념 | 핵심 공식 / 계산 기준 | 대표 사용 위치와 이유 |
|---|---|---|
| **퍼셉트론** | $z = \sum_i w_i x_i + b, \hat{y} = f(z)$ | 뉴런: 입력을 가중합으로 판단 |
| **Sigmoid** | $\sigma(z) = 1/(1+e^{-z})$ | 이진 분류 출력층: 확률 |
| **Softmax** | $p_k = e^{z_k} / \sum_j e^{z_j}$ | 다중 분류 출력층: 합 1 확률 |
| **ReLU** | $ReLU(z) = \max(0, z)$ | 은닉층: 비선형 특징 |
| **선형 출력** | $g(z) = z,\ g\prime(z) = 1$ | 회귀 출력층: 실수 직접 출력 |
| **순전파** | $z = Wa + b,\ a' = f(z)$ | 입력에서 출력까지 예측 계산 |
| **MSE** | $\frac{1}{N}\sum_i (y_i - \hat{y}_i)^2$ | 회귀 손실: 수치 오차 |
| **BCE** | $-[y \ln p + (1-y)\ln(1-p)]$ | 이진 분류 손실: 확률 오차 |
| **CCE** | $-\sum_k y_k \ln p_k$ | 다중 분류 손실: 정답 확률 |
| **선형+제곱오차** | $\partial L/\partial w = 2(\hat{y} - y)x$ | 회귀 출력층 기울기(단일 샘플) |
| **Sigmoid+BCE** | $\partial L/\partial w = (p - y)x$ | 이진 분류 출력층 기울기 |
| **Softmax+CCE** | $\partial L/\partial w_k = (p_k - y_k)x$ | 다중 분류 출력층 기울기 |
| **은닉층 역전파** | $\delta_j = \delta_o v_j f'(a_j)$ | 은닉층 기울기를 뒤에서 전달 |
| **경사하강법** | $w_{new} = w_{old} - \eta \partial L/\partial w$ | 전체 학습 가중치 수정 |

## 실수하기 쉬운 네 가지

1. **순전파와 역전파의 값을 이어서 사용:** 손실 계산 때 임의의 새로운 예측값으로 바꾸지 않습니다.
2. **역전파와 경사하강법 구분:** 기울기 계산과 매개변수 수정은 다른 단계입니다.
3. **출력층에 맞는 손실 선택:** 회귀=MSE, 이진=Sigmoid+BCE, 배타적 다중=Softmax+CCE가 대표적입니다.
4. **업데이트 시점 주의:** 현재 가중치로 모든 기울기를 계산한 후 함께 업데이트합니다.

## 기호 사전: 동일한 기호라도 단계에 따라 구분하기

| 기호 | 의미 |
|---|---|
| $z$ **또는** $a_j$ | 활성화 함수 적용 이전의 가중합(뉴런 점수) |
| $h_j$ **또는** $a^{(\ell)}$ | 활성화 함수 적용 이후의 은닉층 출력 |
| $p$ **또는** $\hat{y}$ | 출력층의 예측 확률 또는 예측값 |
| $L$ | 정답과 예측의 차이를 수치화한 손실 |
| $\delta$ | 해당 뉴런 가중합에 대한 손실 기울기 |
| $\eta$ | 경사하강법의 업데이트 크기를 정하는 학습률 |

**참고 기준:** 본 자료의 공통 숫자 예제와 Sigmoid+BCE 및 Softmax+CCE 기울기 예제는 사용자가 제공한 「앱_역전파_숫자예제.pdf」의 수치를 검토하여 반영했습니다. 각 개념의 '언제 · 어디서 · 어떻게 · 왜' 설명과 보충 계산은 본 학습 자료의 확장 설명입니다.